



PROPOSAL TUGAS AKHIR - EC234701

**ANALISIS RETINOPATI DIABETIK DENGAN
IMPLEMENTASI MENGGUNAKAN *RESIDUAL NEURAL
NETWORK***

Satrio Heru Utomo

NRP 0721 19 4000 0053

Dosen Pembimbing

Dr. Supeno Mardi Susiki Nugroho, ST., MT.

NIP 19700313 199512 1 001

Reza Fuad Rachmadi, S.T., M.T., Ph.D

NIP 19850403 201212 1 001

Program Studi Sarjana Teknik Komputer

Departemen Teknik Komputer

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2024

[Halaman ini sengaja dikosongkan]

LEMBAR PENGESAHAN

ANALISIS RETINOPATI DIABETIK DENGAN IMPLEMENTASI MENGGUNAKAN *RESIDUAL NEURAL NETWORK*

PROPOSAL TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat memperoleh gelar Sarjana Teknik pada Program Studi S-1

Teknik Komputer

Departemen Teknik Komputer

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Oleh: **Satrio Heru Utomo**

NRP. 0721 19 4000 0053

Disetujui Oleh:

Dr. Supeno Mardi Susiki Nugroho, ST., MT.

NIP: 19700313 199512 1 001

(Pembimbing)

Reza Fuad Rachmadi, S.T., M.T., Ph.D

NIP: 19850403 201212 1 001

(Ko-Pembimbing)

SURABAYA

Mei, 2024

[Halaman ini sengaja dikosongkan]

ABSTRAK

ANALISIS RETINOPATI DIABETIK DENGAN IMPLEMENTASI MENGUNAKAN *RESIDUAL NEURAL NETWORK*

Nama Mahasiswa / NRP: Satrio Heru Utomo / 0721 19 4000 0053

Departemen : Teknik Komputer FTEIC - ITS

**Dosen Pembimbing : 1. Dr. Supeno Mardi Susiki Nugroho, ST., MT.
2. Reza Fuad Rachmadi, S.T., M.T., Ph.D**

Abstrak

Retinopati diabetik (DR) adalah komplikasi mikrovaskular diabetes dan merupakan penyebab utama kebutaan di antara orang dewasa usia kerja di seluruh dunia. Deteksi dan intervensi dini sangat penting untuk mencegah kehilangan penglihatan dan meningkatkan hasil pengobatan pasien. Namun, metode skrining tradisional sering kali memiliki keterbatasan dalam hal akurasi dan aksesibilitas. Penelitian ini mengusulkan penerapan Residual Neural Network (ResNet) untuk deteksi dan klasifikasi DR secara otomatis dari gambar fundus. Penelitian ini bertujuan untuk berkontribusi pada kemajuan diagnosis DR otomatis dan pada akhirnya meningkatkan perawatan pasien melalui intervensi dini dan strategi perawatan yang dipersonalisasi.

Kata Kunci: *Retinopati Diabetik, ResNet, Deep Learning, Analisis Angiografi OCT*

[Halaman ini sengaja dikosongkan]

ABSTRACT

ANALYSIS OF DIABETIC RETINOPATHY WITH IMPLEMENTATION USING RESIDUAL NEURAL NETWORK

Student Name / NRP: Satrio Heru Utomo / 0721 19 4000 0053

Department : Computer Engineering ELECTICS - ITS

Advisor : 1. Dr. Supeno Mardi Susiki Nugroho, ST., MT.
2. Reza Fuad Rachmadi, S.T., M.T., Ph.D

Abstract

Diabetic retinopathy (DR) is a microvascular complication of diabetes and is the leading cause of blindness among working-age adults worldwide. Early detection and intervention are crucial to prevent vision loss and improve patient outcomes. However, traditional screening methods often face limitations in accuracy and accessibility. This study proposes the implementation of a Residual Neural Network (ResNet) for automated DR detection and classification from fundus images. By achieving these objectives, this study aims to contribute to the advancement of automated DR diagnosis and ultimately improve patient care through early intervention and personalized treatment strategies.

Keywords: *Diabetic retinopathy, ResNet, Deep Learning, Optical Coherence Tomography Angiography Analysis*

[Halaman ini sengaja dikosongkan]

DAFTAR ISI

[Halaman ini sengaja dikosongkan]

DAFTAR GAMBAR

[Halaman ini sengaja dikosongkan]

DAFTAR TABEL

[Halaman ini sengaja dikosongkan]

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Pada era teknologi digital saat ini, penggunaan kecerdasan buatan sangatlah erat pada aspek kehidupan manusia. Mulai dari membantu produktifitas seperti: rekomendasi konten pada social media, asisten virtual, filter spam; meningkatkan efisiensi, seperti: system transportasi cerdas dan penjadwalan otomatis; hiburan, dan dalam sektor penelitian dan pengembangan dalam sains dan teknologi.

Retinopati diabetik adalah komplikasi mikrovaskular diabetes melitus (DM) yang disebabkan oleh kerusakan pembuluh darah di retina. Penyakit ini dapat menyebabkan penurunan penglihatan, bahkan kebutaan[1]. Menurut Organisasi Kesehatan Dunia (WHO), sekitar 9,3 juta orang di dunia menderita kebutaan akibat diabetic retinopathy. Jumlah ini diperkirakan akan meningkat menjadi 12,6 juta pada tahun 2040.

Hal ini membuat diagnosis dini retinopati diabetik sangat penting untuk mencegah progresi penyakit dan mengurangi risiko komplikasi serius. Penggunaan teknologi dalam dunia medis, terutama di bidang pemrosesan citra medis, telah menjadi bagian integral dari upaya untuk meningkatkan deteksi dini retinopati diabetik. Salah satu metode yang dipahami dengan baik dan memiliki banyak alat yang dikembangkan untuk analisis lebih dalam adalah Residual Neural Network (ResNet).

ResNet adalah jaringan *neural network* yang dirancang untuk mengatasi masalah penurunan kinerja pada jaringan saraf yang lebih dalam. Mekanisme residual memungkinkan ResNet untuk mengoptimalkan pembelajaran jaringan pada data yang kompleks, seperti gambar medis. Tujuan dari penelitian ini adalah untuk menganalisis retinopati diabetik dengan mengimplementasikan Konvolusi Jaringan Saraf Tiruan.

1.2 Rumusan Masalah

Berdasarkan hal yang telah dipaparkan di latar belakang, didapatkan rumusan masalah sebagai berikut:

1. Bagaimana model ResNet dapat dilatih untuk secara akurat mendeteksi keberadaan diabetic retinopathy pada citra fundus mata?
2. Apakah model ResNet dapat secara efektif mengklasifikasikan tingkat tingkat resiko retinopati diabetik (sehat, non-proliferatif, proliferasi) berdasarkan citra fundus mata?
3. Faktor-faktor apa yang mempengaruhi kinerja model ResNet dalam analisis retinopati diabetik pada citra fundus mata?

1.3 Tujuan

Tujuan dari penelitian ini adalah:

1. Mengetahui kemampuan ResNet dalam mengidentifikasi keberadaan diabetic retinopathy pada citra fundus mata.
2. Mengkaji efektivitas ResNet dalam mengklasifikasikan tingkat keparahan retinopati diabetik menjadi sehat, sedang, dan berat.

3. Menganalisis cara model deep learning mendeteksi dan mengklasifikasikan retinopati diabetik. Analisis ini akan fokus pada faktor-faktor yang mempengaruhi kinerja ResNet dalam menganalisis citra fundus mata untuk membuat keputusan.

1.4 Batasan Masalah

Berdasarkan rumusan masalah yang telah dijelaskan sebelumnya, maka penelitian ini memiliki batasan masalah sebagai berikut:

1. Pembatasan penyakit yaitu Diabetic Retinopathy.
2. Pengelompokan berdasarkan tiga tingkatan: Sehat, non-proliferatik, dan proliferasi
3. Dataset yang digunakan berasal dari Diabetic Retinopathy Analysis Grand Challenge.
4. Citra fundus yang dipakai merupakan dalam bentuk hitam-putih.

1.5 Manfaat

Manfaat dari penelitian ini adalah:

1. Meningkatkan akurasi diagnosis retinopati diabetik
2. Mempercepat proses diagnosis retinopati diabetik
3. Meningkatkan ketersediaan layanan retinopati diabetik

BAB 2 TINJAUAN PUSTAKA

2.1 Hasil penelitian/perancangan terdahulu

2.1.1 *Classification of Diabetic Retinopathy Based on B-ResNet*

Zhang dan rekan [2] pada penelitiannya menggunakan data set Eye-PACS, MESSIDOR-2, dan IDRiD untuk membangun data set DR dengan pembersihan, penguatan, dan normalisasi gambar. Selain itu, digunakan metode prapemrosesan gambar yang ditingkatkan untuk meningkatkan fitur gambar fundus. Model B-ResNet dibangun dengan menggabungkan keunggulan ekstraksi fitur ResNet50 dan fusi fitur BCNN. Selain itu, sebelum fusi fitur, gambar fitur yang diekstraksi oleh ResNet50 diproses oleh modul perhatian saluran. ResNet50 dipelajari pada data set ImageNet dan parameternya di-fine-tune melalui transfer learning.

Hasil penelitian menunjukkan bahwa model B-ResNet mencapai akurasi 71,11% , ACA 0,714, Kappa 0,634, dan macro-F1 0,711. Hasil ini lebih tinggi daripada penelitian sebelumnya. Percobaan perbandingan membuktikan bahwa metode prapemrosesan gambar yang ditingkatkan meningkatkan akurasi, ACA, Kappa, dan nilai macro-F1 model.

2.1.2 *A Deep Learning Framework for Detection and Classification of Diabetic Retinopathy in Fundus Images Using Residual Neural Networks*

Abini dan rekan [3] melakukan studi menggunakan model ResNet, yang dilatih dengan dataset APTOS, untuk melakukan klasifikasi biner dan multikelas menggunakan jaringan saraf konvolusional dalam (deep convolutional neural network). Hasil eksperimen menunjukkan bahwa model dengan lapisan dalam seperti ResNet-50 dapat meningkatkan kinerja keseluruhan dataset. Ini mengindikasikan bahwa penggunaan model ResNet-50 dalam klasifikasi DR dapat menjadi lebih efisien dalam hal waktu, tenaga kerja, dan biaya dibandingkan dengan metode diagnostik manual.

2.2 Teori/Konsep Dasar

2.2.1 Pengolahan Citra

Pengolahan citra adalah suatu proses yang mengubah citra menjadi citra lain yang lebih baik dan lebih sesuai dengan kebutuhan. Pengolahan citra dibagi menjadi dua, yaitu pengolahan citra analog dan pengolahan citra digital. Pengolahan citra analog adalah pengolahan citra yang dilakukan pada citra analog. Pengolahan citra digital adalah pengolahan citra yang dilakukan pada citra digital. Pengolahan citra digital dilakukan dengan menggunakan komputer. Pengolahan citra digital dibagi menjadi beberapa tahap, yaitu prapemrosesan, segmentasi, ekstraksi fitur, dan klasifikasi.

2.2.2 OCT Angiography

OCT Angiography (OCTA) adalah teknologi pencitraan medis non-invasif yang memanfaatkan prinsip Optical Coherence Tomography (OCT) untuk memvisualisasi aliran darah mikro di retina dan koroid. OCTA memberikan informasi struktural dan fungsional jaringan mata secara simultan, memungkinkan diagnosis dan pemantauan penyakit mata yang lebih komprehensif [4].

2.2.3 CNN

CNN adalah salah satu jenis jaringan saraf tiruan yang digunakan untuk pengolahan citra. CNN memiliki arsitektur yang terinspirasi dari visual cortex pada hewan. CNN memiliki lapisan konvolusi dan lapisan pooling. Lapisan konvolusi digunakan untuk mengekstraksi fitur dari citra. Lapisan pooling digunakan untuk mengurangi ukuran citra. CNN memiliki beberapa

jenis arsitektur, yaitu LeNet, AlexNet, VGGNet, GoogLeNet, dan ResNet.

CNN, atau Convolutional Neural Networks, merupakan bagian dari Deep Neural Networks, yang ditandai dengan banyaknya lapisan dalam arsitekturnya. Ini sering digunakan untuk data gambar karena kemampuannya yang efektif dalam mengolah informasi visual. Dalam konteks klasifikasi gambar, penggunaan Multilayer Perceptrons (MLP) seringkali tidak ideal. Hal ini disebabkan oleh keterbatasan MLP dalam mempertahankan informasi spasial dari gambar. Berbeda dengan CNN, MLP memperlakukan setiap piksel gambar sebagai fitur yang terpisah dan tidak terkait, yang dapat mengakibatkan performa klasifikasi yang tidak optimal [5].

2.2.4 ResNet

ResNet adalah salah satu jenis arsitektur CNN yang digunakan untuk pengolahan citra. ResNet memiliki lapisan konvolusi dan lapisan pooling. ResNet memiliki beberapa jenis arsitektur, yaitu ResNet-50, ResNet-101, dan ResNet-152. ResNet-50 memiliki 50 lapisan konvolusi dan lapisan pooling. ResNet-101 memiliki 101 lapisan konvolusi dan lapisan pooling. ResNet-152 memiliki 152 lapisan konvolusi dan lapisan pooling. ResNet-50, ResNet-101, dan ResNet-152 memiliki arsitektur yang sama, yaitu terdiri dari 5 blok. Setiap blok terdiri dari beberapa lapisan konvolusi dan lapisan pooling. ResNet-50, ResNet-101, dan ResNet-152 memiliki lapisan konvolusi dan lapisan pooling yang sama. Perbedaan ResNet-50, ResNet-101, dan ResNet-152 terletak pada jumlah lapisan konvolusi dan lapisan pooling yang dimiliki oleh masing-masing blok [6].

2.2.5 Grad-CAM


Gradient-weighted Class Activation Mapping adalah alat yang membuat heatmap untuk menyorot area gambar yang menurut model deep learning paling penting untuk sebuah keputusan. Alat ini bekerja dengan menganalisis hubungan antara prediksi akhir dan fitur jaringan internal. Hal ini membantu men-debug model, mengidentifikasi bias, dan mengembangkan kepercayaan dalam keputusan AI.

BAB 3 METODOLOGI

3.1 Data dan Peralatan

Data

Data yang digunakan dalam penelitian ini adalah data yang diperoleh dari Diabetic Retinopathy Analysis Grand challenge, berupa citra OCT *angiography*



Gambar 3.1: Contoh Data Citra Retina

Peralatan

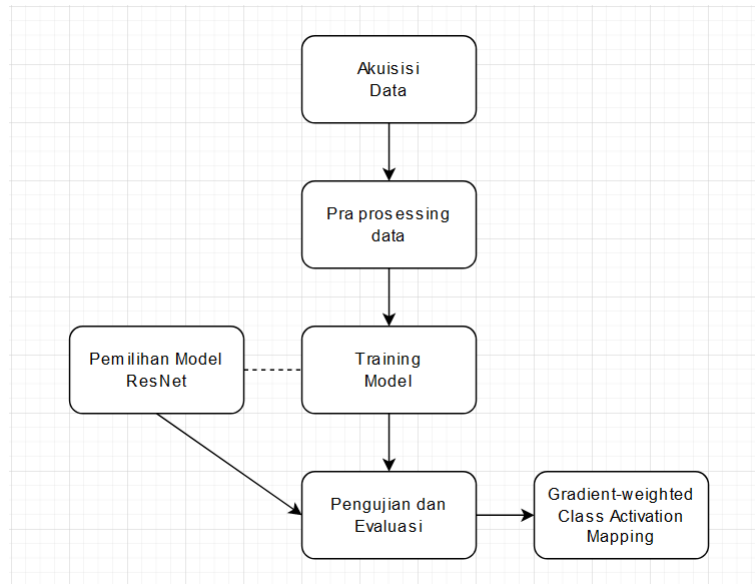
Dalam penelitian ini, penulis menggunakan komputer dengan sistem operasi Windows 11 dengan spesifikasi sebagai berikut:

- Processor: Intel Core i5 12400F
- RAM: 16GB 3200MHz
- GPU: NVIDIA GeForce RTX 3060 Ti
 - CUDA Cores: 4864
 - Memory Config: 8 GB GDDR6

Software yang digunakan dalam penelitian ini adalah sebagai berikut:

- Jupyter Notebook
- Visual Studio Code

3.2 Metode yang digunakan



Gambar 3.2: Diagram blok metodologi

3.2.1 Akuisisi Data

Data yang digunakan dalam penelitian ini adalah data yang diperoleh dari Diabetic Retinopathy Analysis Grand challenge [7]. Data yang digunakan adalah data citra retina yang sudah diberi label berupa tingkat keparahan penyakit retinopati diabetik yang sebelumnya sudah melalui proses image assesment sehingga sudah siap digunakan untuk training model. Dataset ini berisikan 611 citra OCT-A yang telah diberi label. Dataset ini juga berisikan 386 citra OCT-A yang tidak berlabel untuk dijadikan testing dataset.

3.2.2 Pra-pemrosesan Data

Pra-pemrosesan data dilakukan untuk mempersiapkan data sebelum dilakukan proses pelatihan model. Pra-pemrosesan data yang dilakukan adalah konversi citra retina dari format .jpeg menjadi .png. Hal ini dilakukan karena format .png memiliki ukuran yang lebih kecil dibandingkan dengan format .jpeg. Selain itu, format .png juga tidak mengurangi kualitas citra retina. Pra-pemrosesan data juga dilakukan untuk membagi data menjadi data latih dan data uji. Data latih digunakan untuk melatih model sedangkan data uji digunakan untuk menguji model.

3.2.3 Model ResNet

Model ResNet yang akan digunakan untuk dibandingkan dalam penelitian ini adalah model pre-trained resnet-18, resnet-34, resnet-50, resnet-101, dan resnet-152. Performa model-model tersebut akan dibandingkan dengan melihat nilai akurasi, *loss*, dan *val_loss*.

3.2.4 Pelatihan Model

Pelatihan model dilakukan dengan menggunakan metode *transfer learning*. Metode *transfer learning* dilakukan dengan menggunakan model ResNet yang sudah dipilih dan sudah dilatih dengan dataset ImageNet.

3.2.5 Pengujian dan Evaluasi

Pengujian dan evaluasi dilakukan dengan menggunakan data uji. Pengujian dan evaluasi dilakukan dengan melihat nilai akurasi, *loss*, dan *val_loss*. Selain itu, pengujian dan evaluasi juga dilakukan dengan melihat *confusion matrix* dari model yang sudah dilatih, untuk dilihat

nilai presisi, recall, dan F1 pada setiap kelasnya, untuk melihat performa model dalam memprediksi tingkat keparahan penyakit retinopati diabetik.

3.2.6 Gradient-weighted Class Activation Mapping

Grad-CAM digunakan untuk mengetahui faktor-faktor yang mempengaruhi model dalam memprediksi tingkat keparahan penyakit retinopati diabetik. Grad-CAM bekerja dengan menghitung gradien output model terhadap input, dan kemudian menggunakan gradien tersebut untuk memprediksi area input yang paling berkontribusi pada output model.

[Halaman ini sengaja dikosongkan]

BAB 4 HASIL DAN PEMBAHASAN

Pada penelitian ini dipaparkan hasil penelitian serta analisis dari model klasifikasi yang telah dibuat sesuai dengan desain sistem dan implementasi pada Bab 3. Data yang digunakan pada pengujian ini menggunakan dataset DRAC dengan data splitting yang telah dilakukan pra-pemrosesan sebelumnya.

4.1 Hasil Penelitian


4.2 Hasil Pengujian

4.2.1 Hasil pengujian Model tanpa menggunakan penyesuaian apapun


Tabel 4.1: Hasil training best model tanpa melalui penyesuaian class dataset

ResNet architecture	class	acc	prec	rec	F1
18	non-DR		0,861538	0,848485	0,854962
	NPDR	0,7642	0,652174	0,697674	0,674157
	PDR		0,666667	0,571429	0,615385
34	non-DR		0,857143	0,818182	0,837209
	NPDR	0,7724	0,666667	0,790698	0,723404
	PDR		0,777778	0,5	0,608696
50	non-DR		0,808824	0,833333	0,820896
	NPDR	0,6992	0,581395	0,581395	0,581395
	PDR		0,5	0,428571	0,461538
101	non-DR		0,909091	0,909091	0,909091
	NPDR	0,8049	0,711111	0,744186	0,727273
	PDR		0,583333	0,5	0,538462
152	non-DR		0,852459	0,787879	0,818898
	NPDR	0,7398	0,603774	0,744186	0,666667
	PDR		0,777778	0,5	0,608696

4.2.2 Hasil Pengujian Model dengan penyesuaian menggunakan class-weight




Gambar 4.1: Training Loss dan Akurasi ResNet-18




[width=]


Gambar 4.2: Training Loss dan Akurasi ResNet-34




Gambar 4.3: Training Loss dan Akurasi ResNet-50




Gambar 4.4: Training Loss dan Akurasi ResNet-101




Gambar 4.5: Training Loss dan Akurasi ResNet-152



Gambar 4.6: Image A



Gambar 4.7: Image D



Tabel 4.2: Hasil best trained model menggunakan class-weight adjustment

ResNet architecture	class	acc	prec	rec	F1	QWK
18	non-DR	0,7886	0,875	0,848485	0,861538	0.7526956474324895
	NPDR		0,704545	0,72093	0,712644	
	PDR		0,666667	0,714286	0,689655	
34	non-DR	0,7236	0,877193	0,757576	0,813008	0.7344195070936137
	NPDR		0,617021	0,674419	0,644444	
	PDR		0,526316	0,714286	0,606061	
50	non-DR	0,7317	0,848485	0,848485	0,848485	0.7416221605070141
	NPDR		0,634146	0,604651	0,619048	
	PDR		0,5	0,571429	0,533333	
101	non-DR	0,7642	0,916667	0,833333	0,873016	0.7133252550521831
	NPDR		0,666667	0,651163	0,658824	
	PDR		0,52381	0,785714	0,628571	
152	non-DR	0,7805	0,870968	0,818182	0,84375	0.7423939072743689
	NPDR		0,714286	0,697674	0,705882	
	PDR		0,631579	0,857143	0,727273	

Tabel 4.3: Hasil best validated model menggunakan class-weight adjustment

ResNet architecture	class	acc	prec	rec	F1	QWK
18	non-DR	0,813	0,869565	0,909091	0,888889	0.6266311390141076
	NPDR		0,717391	0,767442	0,741573	
	PDR		0,875	0,5	0,636364	
34	non-DR	0,7886	0,777778	0,954545	0,857143	0.6915275416648504
	NPDR		0,88	0,511628	0,647059	
	PDR		0,705882	0,857143	0,774194	
50	non-DR	0,7805	0,84058	0,878788	0,859259	0.7084479219119185
	NPDR		0,690476	0,674419	0,682353	
	PDR		0,75	0,642857	0,692308	
101	non-DR	0,7886	0,907692	0,893939	0,900763	0.7076588090504592
	NPDR		0,72973	0,627907	0,675	
	PDR		0,52381	0,785714	0,628571	
152	non-DR	0,8049	0,870968	0,818182	0,84375	0.7052973650209466
	NPDR		0,733333	0,767442	0,75	
	PDR		0,75	0,857143	0,8	

4.2.3 Analisis Hasil

BAB 5 PENUTUP

[Halaman ini sengaja dikosongkan]

DAFTAR PUSTAKA

- [1] M. Yusran, “Kecerdasan buatan dalam diagnosis retinopati diabetik,” *Jurnal Kedokteran Universitas Lampung*, vol. 6, no. 1, 2022. doi: <https://doi.org/10.23960/jkunila6116-20>.
- [2] Q. Zhang, J. Li, X. Liang, J. Zhang, and X. Wei, “Classification of diabetic retinopathy based on b-resnet,” in *2022 7th IEEE International Conference on Data Science in Cyberspace (DSC)*, IEEE, 2022.
- [3] M. Abini and S. S. S. Priya, “A deep learning framework for detection and classification of diabetic retinopathy in fundus images using residual neural networks,” in *2023 9th International Conference on Smart Computing and Communications (ICSCC)*, 2023, pp. 55–60. doi: [10.1109/ICSCC59169.2023.10335079](https://doi.org/10.1109/ICSCC59169.2023.10335079).
- [4] A. H. Kashani, C.-L. Chen, J. K. Gahm, *et al.*, “Optical coherence tomography angiography: A comprehensive review of current methods and clinical applications,” *Prog. Retin. Eye Res.*, vol. 60, pp. 66–100, Sep. 2017.
- [5] D. L. Z. Astuti and Samsuryadi, “Kajian pengenalan ekspresi wajah menggunakan metode pca dan cnn,” *Annual Research Seminar of the Faculty of Computer Science*, vol. 4, no. 1, pp. 293–297, 2018.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.
- [7] D. Challenge, *Diabetic retinopathy analysis challenge dataset*, Zenodo, Dec. 2023. doi: [10.5281/zenodo.10280359](https://doi.org/10.5281/zenodo.10280359). [Online]. Available: <https://doi.org/10.5281/zenodo.10280359>.